

Árboles de Decisión y Clasificación en Machine Learning

Competencia: Python (Machine Learning)

Instructor


Martha Ester Gómez Adasme

Aprendices

- Samuel Gutierrez Franco
- Henry Jafet Caballero Mendoza
- Juan José Gallego Bran
- Emanuel Henao González
- Alexis Gómez Pavas

Centro de Servicios y Gestión Empresarial





¿Qué es un Árbol de Decisión?

Aprendizaje Supervisado

Método no paramétrico utilizado para **clasificación y regresión**, sin supuestos sobre la distribución de los datos.


Estructura Jerárquica

Aprende reglas **if-then-else** a partir de los datos de entrenamiento de forma automática.

Particionamiento Recursivo

Predice valores dividiendo el dominio de entrada en regiones cada vez más específicas.

Componentes del Árbol de Decisión



Anatomía del Árbol

Nodo Raíz

Punto de inicio: primera pregunta sobre los datos.

Nodos Internos

Evalúan características y dividen los datos en subgrupos.

Ramas

Representan los resultados posibles de cada evaluación.

Nodos Hoja

Contienen las predicciones finales (clases o valores).

Ventajas de los Árboles de Decisión



Interpretabilidad

Sencillo de entender e interpretar.
Los árboles pueden ser **visualizados** fácilmente, incluso por personas sin experiencia técnica.



Preparación Mínima

Requiere **poca preparación de datos**. No necesita normalización ni estandarización de variables.



Versatilidad

Maneja tanto **datos numéricos como categóricos** en el mismo modelo sin transformaciones especiales.

Criterios de División: Impureza de Gini



¿Qué mide el Índice de Gini?

Mide la **probabilidad de clasificar incorrectamente** una muestra elegida al azar si se etiquetara según la distribución de clases en el nodo.

- ❑ El algoritmo busca siempre minimizar la impureza de Gini al elegir la mejor división.

Gini = 0

Nodo **puro**: todas las muestras pertenecen a una sola clase.

Gini $\approx$ 0.5


Máxima mezcla en clasificación binaria: clases completamente mezcladas.

Criterios de División: Entropía

Entropía y Teoría de la Información

La entropía proviene de la **teoría de la información**. Se maximiza cuando las clases están distribuidas de forma equitativa y es **cero cuando el nodo es puro**.

- **Ganancia de información:** reducción de entropía lograda tras realizar una división.
- **Criterio de selección:** el algoritmo elige la división con mayor ganancia de información.




Top Down Induction of Decision Trees

Elige la variable más **informativa** en cada nodo.

Divide los datos según los **valores** de esa variable.

Construye **subárboles** recursivamente para cada partición.

Se detiene cuando todos los patrones son de la **misma clase**.



Implementación en Python con Scikit-Learn

DecisionTreeClassifier

Clase principal de Scikit-Learn que permite **entrenar un clasificador de árbol de decisiones** con pocas líneas de código.



fit(X, y)

Entrena el modelo con los datos de entrenamiento.

predict(X)

Genera predicciones para nuevas muestras.

score(X, y)

Calcula la precisión del modelo sobre un conjunto de datos.

Hiperparámetros Importantes

1

criterion

'gini' o 'entropy' — define la función para medir la calidad de cada división del árbol.

2

max_depth

Profundidad máxima del árbol. Limitar este valor es la principal estrategia para **prevenir el sobreajuste**.

3

min_samples_split

Número mínimo de muestras requeridas para **dividir un nodo** interno.


4

min_samples_leaf


Número mínimo de muestras que deben existir en los **nodos hoja** del árbol.

Prevención del Sobreajuste


1) Limitar profundidad (max_depth) - restrict tree depth




2) Aumentar muestras mínimas por nodo - more samples per node



3) Validación cruzada - cross-validate to evaluate performance



4) Técnicas de poda - prune to simplify the model



¿Por qué ocurre el sobreajuste?

Un árbol sin restricciones puede memorizar los datos de entrenamiento, perdiendo capacidad de **generalizar** a datos nuevos.

- **Limitar max_depth** evita que el árbol crezca demasiado.
- **Aumentar muestras mínimas** por nodo reduce divisiones innecesarias.
- **Validación cruzada** permite evaluar el rendimiento real del modelo.
- **Poda (pruning)** simplifica el modelo eliminando ramas poco informativas.

❏ Un buen modelo equilibra precisión en entrenamiento con capacidad de generalización.

Conclusión: Árboles de Decisión

1

Modelos Intuitivos

Los árboles de decisión son herramientas poderosas y **fácilmente interpretables**, generando reglas "if-then-else" que replican la toma de decisiones humana.

2

Versatilidad de Datos

Manejan eficazmente **datos numéricos y categóricos** con mínima preparación, adaptándose a diversas aplicaciones de clasificación y regresión.

3

Criterios de División

Utilizan métricas como la **Impureza de Gini** o la **Entropía** para determinar la mejor manera de dividir los nodos y construir un árbol óptimo.

4

Control de Complejidad

Es crucial gestionar el sobreajuste mediante **hiperparámetros** como `max_depth` y `min_samples_leaf`, garantizando la capacidad de generalización del modelo.